

CAHIER DES CHARGES – PROJET FIL ROUGE DATA ANALYST

Projet Data Analytics Fil Rouge

Réalisé par : Mawada Ennaciri

Encadré par : **Yassine Ammami**

Année universitaire : 2025 – 2026

1 Intitulé du projet

Analyse des logements énergivores (“passoires thermiques”) afin de prioriser les stratégies de rénovation énergétique à partir des données territoriales et socio-économiques

2 Contexte métier

La transition énergétique est une priorité nationale en France.
Les logements classés **F et G au DPE** (appelés *passoires thermiques*) représentent un enjeu majeur :

- précarité énergétique des ménages,
- émissions élevées de CO₂,
- coûts importants pour les collectivités.

Les pouvoirs publics doivent **prioriser les rénovations** en fonction :

- de la performance énergétique,
 - du niveau de revenu des habitants,
 - de la densité de population,
 - du territoire.
-

3 Problématique analytique

Quelles communes présentent la plus forte concentration de logements énergivores, combinée à une population vulnérable économiquement, et doivent être prioritaires pour les politiques de rénovation énergétique ?

4 Objectifs du projet

- Identifier les communes à forte proportion de passoires thermiques
 - Croiser DPE ↔ revenus ↔ population ↔ territoire
 - Construire des **indicateurs de priorité de rénovation**
 - Fournir une **analyse data-driven** exploitable par une collectivité
 - Produire des **dashboards clairs et cartographiques**
-

📍 France – échantillon de 2 à 3 régions uniquement :

- Île-de-France
- Hauts-de-France
- Bretagne

6 Datasets – Sources EXACTES & types

✓ Option 2 Simplon — 3 types de sources différentes

Type de source	Dataset	Format	Utilité
Type 1 — API REST	DPE logements (ADEME)	JSON / API paginée	Passoires thermiques F/G
Type 1 — API REST	Population communale	JSON (geo.api.gouv.fr)	Densité & comparaisons
Type 1 — API REST	Géographie communes	GeoJSON (contours)	Cartographie Power BI
Type 2 — Fichier CSV	Revenus INSEE Filosofi	CSV/ZIP (téléchargé)	Précarité économique
Type 3 — Base SQL	Logements RP2022 (SQLite)	SQLite + requêtes SQL	Parc immobilier total

1 Données DPE des logements [API REST]

Type : données énergétiques — API ADEME data.ademe.fr

Format : JSON / API REST paginée (fallback : CSV simulé structure ADEME)

Contenu :

- classe énergétique des logements (A à G)
- type de logement (maison, appartement)
- année de construction
- code INSEE de la commune
- consommation énergie primaire (kWh/m²/an)

Utilité :

- identifier les logements énergivores (passoires thermiques F/G)
- base principale de l'analyse énergétique

2 Données population communale [API REST]

Type : données démographiques — geo.api.gouv.fr / INSEE

Format : JSON via API REST par département (fallback : CSV data.gouv.fr)

Contenu :

- population totale par commune
- évolution démographique
- code INSEE de la commune
- code département et région

Utilité :

- rapporter les passoires thermiques à la population
- comparer les communes entre elles

3 Données revenus communaux [CSV/ZIP]

Type : données socio-économiques — INSEE Filosofi

Format : fichier ZIP/CSV téléchargé (encodage latin-1, séparateur ;)

Contenu :

- revenu médian par commune (MED21)
- niveau de vie des ménages
- indicateurs de précarité (taux pauvreté TP6021)
- code INSEE de la commune

Utilité :

- analyser la capacité financière des ménages
- prioriser les aides à la rénovation

4 Données logements – Parc immobilier [Base SQL]

Type : données de logement — INSEE RP2022 → base SQLite

Format : base SQLite avec 2 tables + 1 vue SQL (export CSV pour Power BI)

Contenu :

- nombre total de logements par commune
- résidences principales (NB_RP)
- logements vacants (NB_LOGVAC)
- maisons / appartements (NB_MAISON / NB_APPART)
- code INSEE de la commune

Utilité :

- contextualiser les données DPE
- calculer des ratios (passoires / logements)

5 Données géographiques communales [API REST]

Type : données géospatiales — geo.api.gouv.fr / IGN

Format : GeoJSON (contours communes, filtré par département)

Contenu :

- contours géographiques des communes (polygones)
- code INSEE de la commune

Utilité :

◦ cartographie des résultats

- visualisation territoriale dans Power BI ou Python (GeoPandas / Folium)

6 Données comparatives énergie-climat [OPTIONNEL]

Type : données environnementales agrégées

Format : Excel / CSV

Contenu :

- indicateurs énergie / climat par territoire
- données de comparaison régionale

Utilité :

- enrichir l'analyse
- mise en perspective territoriale

7 Clé de jointure (très important)

Clé commune à TOUS les datasets : **code_insee_commune**

Dataset	Nom de la colonne	Type source
Population	CODGEO	API REST
Revenus	Code_commune / CODGEO	CSV/ZIP
Logements RP2022	codgeo / CODGEO	Base SQL (SQLite)
DPE	code_insee_commune_actualise	API REST
Géographie (GeoJSON)	code ou insee_com	API REST

8 Indicateurs & KPI envisagés

- **% de logements classés F/G par commune**
- Nombre de passoires thermiques / 1 000 habitants
- Revenu médian vs classe énergétique (corrélation)
- **Indice de priorité de rénovation (score composite)**

Formule du score composite

$$\text{Score} = (\% \text{ logements F/G}) \times 0.40 + (1 - \text{revenu normalisé}) \times 0.35 + (\text{densité passoires/1000 hab}) \times 0.25$$

9 Outils &

technologies envisagés

- Python : Pandas, NumPy, GeoPandas
- SQL : PostgreSQL / SQLite
- Power BI : dashboards & cartes
- VS Code : développement
- Git / GitHub : versioning
- JIRA
- CONFLUENCE
- API REST : DPE (ADEME)
- (Databricks optionnel si volumétrie élevée)

Outil	Usage
Python (Pandas, NumPy, GeoPandas)	Collecte, nettoyage, analyse, pipeline
SQLite + SQL	Stockage Type 3 — logements RP2022
Power BI	Dashboards interactifs & cartes choroplèthes
Git / GitHub	Versioning, documentation, livrable GitHub
VS Code / Jupyter	Développement et notebooks EDA
JIRA / Confluence	Gestion de projet et documentation
API REST ADEME + geo.api.gouv.fr	Extraction données DPE et géo (Type 1)
Databricks (optionnel)	Si volumétrie élevée — traitement distribué

10 Livrables attendus

- **Base de données nettoyée et consolidée (CSV + SQLite)**
- Notebook EDA — analyse exploratoire complète
- **Scripts Python de collecte, nettoyage, fusion et KPI**
- **Dashboard Power BI interactif + carte choroplèthe**
- **Rapport data storytelling (contexte → démarche → résultats → recommandations)**
- Support de présentation (slides narratifs)
- Repository GitHub documenté avec README

Planning

prévisionnel

Semaine	Étape	Livrables
S1 – S2	Collecte & chargement des données	Scripts Python, base SQLite
S3	Nettoyage, fusion, jointures	Dataset consolidé
S4	EDA & analyse exploratoire	Notebook EDA
S5	Score composite & clustering	Indicateurs KPI
S6	Dashboard Power BI + carte	Dashboard final
S7	Rapport, slides, GitHub, soutenance	Tous livrables

10 Livrables attendus

- Base de données nettoyée et consolidée
- Notebook EDA
- Scripts de fusion & préparation
- Dashboard Power BI
- Slides
- Documentation du data
- Repository GitHub documenté